

MODELADO DE LA DEGRADACIÓN DEL DESEMPEÑO DE UNA TURBOMÁQUINA USANDO APRENDIZAJE AUTOMÁTICO

Ronny Portillo^{1*}, Alí Gabriel Lara², Andrés Rosales³

¹*Escuela de Ingeniería Química Facultad de Ingeniería. Universidad Central de Venezuela*
Portillorronny6@gmail.com

RESUMEN

Como principal fuente de energía para aeronaves, la fiabilidad de un motor aerodinámico es fundamental para garantizar la seguridad de las aeronaves. Los pronósticos y la gestión de salud (PHM) en un motor aero no solo pueden mejorar su seguridad, estrategia de mantenimiento y disponibilidad, sino también reducir sus costos de operación y mantenimiento. La estimación de la vida útil residual (RUL) es una tecnología clave en la investigación de PHM. Los datos normales sin signos de degradación pueden actuar como ruido en el entrenamiento y evitar que el modelo de estimador RUL aprenda los patrones de degradación. Esto puede degradar significativamente el rendimiento de la estimación RUL. Por lo tanto, es crítico identificar el modo de degradación durante el paso de entrenamiento. Además, predecir el RUL cuando el sistema está en modo normal y no muestra ningún signo de degradación puede generar estimaciones inexactas y reducir la confianza en el modelo. En este documento, proponemos un método de estimación del RUL que aplica una red neuronal de memoria a corto a largo plazo (LSTM) para predecir el RUL del sistema. Como caso de estudio, aplicamos el método propuesto para la estimación del RUL en la base de datos C-MAPSS. El caso de estudio demuestra que nuestra solución logra una estimación RUL más precisa en comparación con varios métodos de referencia.

Palabras Clave: PHM, tiempo de vida útil remanente, red neuronal, memoria corta a largo plazo, degradación.

ABSTRACT

As the main power source for aircrafts, the reliability of an aero engine is critical for ensuring the safety of aircrafts. Prognostics and health management (PHM) on an aero engine cannot only improve its safety, maintenance strategy and availability, but also reduce its operation and maintenance costs. Residual useful life (RUL) estimation is a key technology in the research of PHM. Normal data with no sign of degradation can act as noise in the training step, and prevent RUL estimator model from learning the degradation patterns. This can degrade RUL estimation performance significantly. Therefore, it is critical to identify degradation mode during the training step. Moreover, in the application step, predicting RUL when the system is in normal mode and is not showing any sign of degradation can generate inaccurate estimations, and reduce faith in the model. In this paper, we propose a RUL estimation method. Long Short Term Memory (LSTM) neural network is applied to predict system RUL. As a case study, we apply the proposed method for RUL estimation in C-MAPPSS Dataset. The case study demonstrates that our solution achieves more accurate RUL estimation compared to several baseline methods.

Keywords: PHM, remaining useful life, neural network, long short-term memory, degradation.

INTRODUCCIÓN

El campo de Pronósticos y Diagnósticos de la Salud (PHM, por sus siglas en inglés), intenta predecir el futuro de un sistema o componente, basado en sus estados pasados y presentes. Un problema común en este campo es la estimación de la vida útil remanente, o la duración de la funcionalidad de un sistema o componente. El mantenimiento basado en la condición es una estrategia que el campo PHM emplea para la toma de decisiones, realizando diagnósticos en tiempo real de fallas inminentes y el pronóstico de la salud futura del equipo, donde la decisión de realizar el mantenimiento se alcanza al observar la "condición" del sistema y sus componentes.

Los costos relacionados con el mantenimiento de turbomáquinas y la necesidad de un alto rendimiento, han generado un interés considerable en las técnicas avanzadas de mantenimiento basadas en la condición y la salud de equipos. Esta investigación diseña un esquema de diagnóstico y pronóstico para estimar la detección de fallas y predecir el tiempo de vida útil remanente para motores aeronáuticos (turbofan), utilizando metodologías basadas en aprendizaje automático para garantizar la seguridad y el rendimiento del equipo. El tiempo de vida útil remanente se predice al emplear redes neuronales artificiales recurrentes con memoria LSTM. Se pueden producir varias degradaciones en el motor que resultan en cambios en el rendimiento de sus componentes. La condición de salud del motor se predice debido a la aparición de estos deterioros.

METODOLOGÍA

1. Investigar sobre el mecanismo y el modelado del proceso de degradación del desempeño de una turbomáquina enfocado en aplicaciones de pronóstico.

Se propone realizar una búsqueda de investigaciones donde se haya estudiado y modelado las degradaciones de motores aeronáuticos. Así mismo, emplear la base de datos que se haya utilizado en alguna de las investigaciones para poder cumplir con el resto de objetivos específicos.

2. Desarrollar un modelo para estimar la degradación del desempeño de una turbomáquina a partir de datos típicos de operación.

- Realizar el preprocesamiento de los datos.
- Empleando un proceso de deep learning, construir una red neuronal artificial para predecir el tiempo de vida útil remanente del equipo.
- Obtener el índice de degradación de la máquina.

3. Caracterizar el proceso de degradación empleando los parámetros: índice de degradación y tiempo de vida útil remanente.

Determinar mediante una gráfica típica de degradación de componentes, como varía la salud de la turbomáquina empleando el índice de degradación y tiempo de vida útil remanente.

RESULTADOS Y DISCUSIÓN

A continuación, presentan los resultados obtenidos en el orden planteado en la sección de metodología.

Tabla N° 1. Estructura de los sensores empleados.

Index	Symbol	Description	Units
1	T2	Total temperature at fan inlet	°R
2	T24	Total temperature at LPC outlet	°R
3	T30	Total temperature at HPC outlet	°R
4	T50	Total temperature at LPT outlet	°R
5	P2	Pressure at fan inlet	psia
6	P15	Total pressure in bypass-duct	psia
7	P30	Total pressure at HPC outlet	psia
8	Nf	Physical fan speed	rpm
9	Nc	Physical core speed	rpm
10	epr	Engine pressure ratio (P50/P2)	--
11	Ps30	Static pressure at HPC outlet	psia
12	phi	Ratio of fuel flow to Ps30	pps/psi
13	NRF	Corrected fan speed	rpm
14	NRC	Corrected core speed	rpm
15	BPR	Bypass Ratio	--
16	farB	Burner fuel-air ratio	--
17	htBleed	Bleed Enthalpy	--
18	Nf_dmd	Demanded fan speed	rpm
19	PCNfR_dmd	Demanded corrected fan speed	rpm
20	W31	HPT coolant bleed	lbm/s
21	W32	LPT coolant bleed	lbm/s

serie de tiempo corresponde a un motor diferente. Cada motor arranca con distintos grados de desgaste inicial y variación de fabricación que es desconocida para el usuario. Este desgaste y variación inicial se consideran normales, es decir, no se considera una condición de falla. Hay tres configuraciones operativas que tienen un efecto sustancial en el rendimiento del turbofan. Estas configuraciones también se incluyen en los datos. Finalmente, los datos también están contaminados con el ruido del sensor.

Los datos de entrenamiento son los datos de ejecución del turbofan desde el estado inicial hasta que ocurre la falla. Los datos de prueba

son los datos de operación del turbofan sin eventos de falla registrados. Los datos RUL, contienen la información de los ciclos verdaderos restantes para cada motor en los datos de prueba.

Procesamiento de los datos

En esta sección se preprocesaron los datos aplicando técnicas estadísticas para observar las distribuciones de los sensores, métricas básicas (desviación estándar, máximos, mínimos, etc), coeficiente de correlación de Spearman, matriz de correlación.

Se identificaron y retiraron los valores atípicos aplicando el algoritmo de aprendizaje no

Los conjuntos de datos que provee la NASA fueron desarrollados empleando el Simulador Comercial de Sistemas de Aeropropulsión Modular (C-MAPSS, por sus siglas en inglés), el cual está hecho bajo Matlab y Simulink^[1] y plantean varios desafíos que han sido abordados por diferentes métodos en la literatura. En particular, los datos tienen alta variabilidad debido al ruido de los sensores, efectos de las condiciones de operación y la presencia de múltiples modos de falla (para tener acceso a los datos, siga el siguiente enlace: <https://goo.gl/W9EPmo>).

Son cuatro conjuntos de datos que consisten en múltiples series de tiempo de sensores. Cada conjunto de datos se divide en subgrupos de entrenamiento, prueba y el tiempo de vida útil remanente (RUL). Cada




Figura N° 1. Localización de los sensores típicos en un turbofan (Richter, 2011).

supervisado Local Outlier Factor (LOF). Luego, se agruparon los datos con el algoritmo DBSCAN. Finalmente se normalizaron los datos y se aplicó una técnica de reducción de dimensiones con el algoritmo de Reducción de Características Recursivas (RFECV).

Red Neuronal Recurrente con neuronas LSTM

Se emplearon redes neuronales recurrentes del tipo LSTM. Las neuronas fueron del tipo Long-Short Term Memory (Memoria corta a largo plazo) debido a referencias^[2] de que este tipo de neuronas son poderosas al trabajar con series de tiempo secuenciales en la detección de anomalías.

Para trabajar con este tipo de red neuronal, es necesario establecer una ventana de operación, también conocida como Longitud de la secuencia, debido a que las neuronas LSTM trabajan por lotes de información. La ventana óptima que se estableció fue de 50 datos^[3]. Quedando la estructura total de los datos para el ejemplo anterior como: (142 x 50 x 23). Esto se realizó con todos los sensores. Una ventaja poderosa de este tipo de red neuronal es que se le incluye el tiempo, por lo tanto, es capaz de aprender de los datos y de las secuencias a los cuales estos pertenecen.

En la fase entrenamiento se probaron con distintas arquitecturas. Sin embargo, como lo reportan en^[3], la mejor arquitectura para ellos fue el tipo LSTM(64,32); NN(8,8), que significa que utilizaron 2 capas LSTM. La primera con 32 neuronas y la segunda con 64 neuronas. Las últimas dos capas tienen neuronas básicas del tipo perceptrón con 8 neuronas en cada capa. Además,




Figura N° 2. Gráfica de la pérdida de los datos de entrenamiento y los de validación de la RNN.

emplearon como función de optimización *Rmsprop* que es una mejora del *Descenso del Gradiente Estocástico*. Además, se utilizaron las mismas métricas de regresión que se emplearon con los algoritmos de aprendizaje automático, es decir, RMSE y R^2 . Por otra parte, el 10% de la base de datos de entrenamiento se utilizó para validar la red neuronal a medida que se iba entrenando para realizar la gráfica de la función de pérdida, que para dicha función la métrica utilizada fue el error cuadrático medio. Finalmente, la función objetivo que se le dio a la red neuronal para que se entrenará y ajustará fue la columna de tiempo de vida útil remanente normalizado de 1 a 0.

Al terminar el entrenamiento de la RNN se observó la gráfica de pérdida para corroborar la convergencia y la ausencia del sobreajuste de la red neuronal (ver Figura 2).

Se observa como la pérdida de entrenamiento y de validación al principio de las épocas son diferentes, pero luego convergen hacia el mismo punto, lo que se interpreta como el hecho de que la red neuronal fue capaz de entrenarse correctamente evitando el sobreajuste de los datos. Las métricas que se obtuvieron con los datos de entrenamiento fueron las siguientes:

Tabla N° 2. Métricas del entrenamiento de la RNN.

Métricas	Puntaje
RMSE	17.188
R^2	0.897

Se ven que las métricas de entrenamiento fueron bastante buenas, sin embargo, no son suficientes para determinar el poder predictivo de la RNN. Por lo tanto, se procedió a probar la red con los datos de prueba para comprobar los resultados y posteriormente las métricas (ver Tabla N°4).


Tabla N°3. Resultados de la RNN.

Máquinas	1	2	3	4	...	97	98	99	100
RUL_norm	0.354	0.436	0.481	0.474	...	0.380	0.327	0.546	0.092
Predichos	0.209	0.265	0.390	0.432	...	0.301	0.165	0.454	0.014

Los resultados que estamos observando es el porcentaje de vida remanente que les queda a las máquinas. Por ejemplo, para la máquina 1, la red neuronal predijo que le restaba el 20% pero en realidad le resta el 35%. A pesar de que pueda parecer una diferencia alarmante, es importante mencionar que para mejorar esa desviación se puede mejorar la arquitectura de la red neuronal, usando más o menos capaz, empleando regularizadores, o simplemente entrenando a la red con más datos.

Tabla N°4. Métricas de la prueba de la RNN.

Métricas	Puntaje
RMSE	25.383
R^2	0.755



Se observa, como era de esperarse, una variación en las métricas que se obtuvieron con los datos de prueba. Estas métricas reportan un puntaje coherente debido a que la red realizó la predicción de datos que no había visto antes y es normal esperar una disminución en las métricas de ajuste. Sin embargo, es importante acotar que la red neuronal aprende de todos los datos nuevos que se le asignen y se mejora automáticamente, es decir, es capaz de tener memoria.

Figura N° 3. Índice de degradación vs Ciclos para una máquina escogida al azar de la base de datos de prueba.

Luego se realizó una gráfica que representará el índice de degradación de cada máquina en función de los ciclos operativos restantes (ver

Figura N° 3). De forma de ejemplo, se tomará la máquina 15. La RNN fue capaz de determinar la progresión de la vida útil de la máquina para el resto de ciclos operativos.

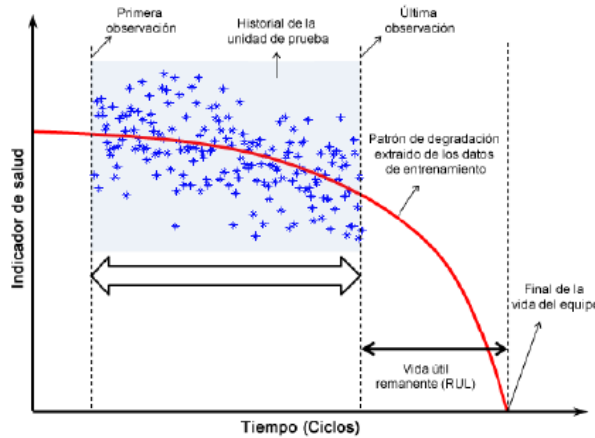


Figura 4. Ilustración de las etapas de la degradación de un activo representando el rango del RUL^[4].

investigaciones que abordan el tema de detección de anomalías^[5].

Ahora bien, teniendo la predicción de la RNN, se propuso determinar un modelo que ajustará lo mejor posible estos datos, y de ese modo, tener una expresión matemática del índice de degradación de la máquina en cuestión.




Figura N° 5. Comportamiento del índice de degradación al evaluarla en distintos ciclos.

En primer lugar, se observa como la gráfica parte desde un porcentaje de vida útil del 74% aprox. Lo que quiere decir, que los datos para la máquina 15 que se tienen en la base de datos de prueba, se reportan hasta el 74% de vida.

En segundo lugar, vemos como la vida útil de la máquina se mantiene prácticamente constante por un periodo de aproximadamente 10 ciclos, luego de ese tiempo, la degradación comienza y el porcentaje de vida disminuye significativamente.

En tercer y último lugar, vemos como la gráfica obtenida se aproxima bastante bien a lo que se viene reportando en la mayoría de las investigaciones que abordan el tema de detección de anomalías^[5].

Al observar la figura N°3, vemos que la tendencia de la curva pareciera seguir un modelo exponencial. Además, tal cual como lo reporta Meher-Homji et al. en su investigación del año 2004 al mostrar el índice de ensuciamiento de un compresor axial, el cual sigue un comportamiento exponencial, la regresión del tipo exponencial parece ser el ajuste que mejor representa las curvas de índice de degradación (ID).

$$y = A \cdot e^{B \cdot x} + C$$

Al realizar el ajuste de los datos predichos, se obtuvo la siguiente ecuación:

$$ID = -0,00561298 \cdot e^{0,13873498 \cdot Ciclos} + 0,749745$$

La ecuación anterior es la ecuación que modela la salud de la máquina 15 en función de los ciclos. Esta ecuación es la representación del índice de degradación de dicha máquina en función los ciclos operativos. Además, viendo la figura N°5, se puede establecer el inicio de la vida útil remanente desde el punto de inflexión hasta que el índice de degradación se hace cero. De esta manera, podemos caracterizar la máquina 15 empleando el índice de degradación y el tiempo de vida útil remanente gracias al modelo matemático obtenido a partir de los datos predichos por la RNN.

CONCLUSIONES

- El área de Pronósticos y Diagnósticos de la salud de equipos está presentando un intenso auge que ha llevado a la NASA a participar en la generación de datos sintéticos de diferentes turbomáquinas.
- El preprocesamiento es la fase que más tiempo consume y es a la que más cuidado hay que prestarle. Específicamente en la limpieza de los datos y remoción de valores atípicos.
- La Red Neuronal Recurrente del tipo LSTM fue capaz de determinar el RUL con unas métricas de ajuste y de poder predictivo muy parecido al del resto de investigaciones.
- Se logró obtener la curva Índice de degradación vs Ciclos empleando los valores predichos de la RNN. Esta curva presentó el mismo comportamiento de otras investigaciones del área.

REFERENCIAS

La cita se hace empleando números arábigos entre corchetes al final de la idea [1] y en estricto orden de aparición.

- [1] Saxena, A. y Goebel, K. (2008). Turbofan engine degradation simulation dataset. NASA Ames Prognostics Data Repository.
- [2] Brownlee, J. (2017). Long short-term memory networks with python develop sequence prediction models with deep learning. Machine Learning Mastery, EBook.
- [3] Zheng, S., Ristovski, K., Farahat, A. y Gupta, C. Long short-term memory network for remaining useful life estimation. In Prognostics and Health Management (ICPHM), 2017 IEEE International Conference on, pages 88–95. IEEE, 2017.
- [4] Wang, T., Yu, J., Siegel, D. y Lee, J. A similarity-based prognostics approach for remaining useful life estimation of engineered systems. In Prognostics and Health Management, 2008. PHM 2008. International Conference on, pages 1–6. IEEE, 2008.
- [5] Li, Y. y Nilkitsaranont, P. (2009). Gas turbine performance prognostic for condition-based maintenance. Applied energy, 86(10): 2152–2161.